

تمرین سوم درس هوش مصنوعی

دانشکده مهندسی برق و کامپیوتر

فرد سیاهکلی ۸۱۰۱۹۸۵۱۰



درخت تصمیم

قسمت اول ابتدا آنتروپی اولیه را حساب کرده و سپس آنتروپی وزن دار را برای هر فیچر محاسبه می کنیم. سپس Information Gain هر کدام نسبت به آنتروپی اولیه را مقایسه می کنیم تا گره اول درخت را تعیین کنیم.

$$I(Ham, Spam) = - \frac{Ham}{Ham + Spam} \log_2(Ham) - \frac{Spam}{Ham + Spam} \log_2(Spam)$$

$$E(Detect) = I(5,9) = 0.94$$

$$AE(Domain) = \frac{6}{14} I(2,4) + \frac{4}{14} I(2,2) + \frac{4}{14} I(1,3) = \frac{6}{14} (0.918) + \frac{4}{14} (1) + \frac{4}{14} (0.811)$$

$$AE(Format) = \frac{8}{14} I(2,6) + \frac{6}{14} I(3,3) = \frac{8}{14} (0.811) + \frac{6}{14} (1)$$

$$AE(Length) = \frac{5}{14} I(2,3) + \frac{5}{14} I(3,2) + \frac{4}{14} I(0,4) = \frac{5}{14} (0.971) + \frac{5}{14} (0.971) + \frac{4}{14} (0)$$

$$AE(Complain) = \frac{7}{14} I(4,3) + \frac{7}{14} I(1,6) = \frac{7}{14} (0.985) + \frac{7}{14} (0.592)$$

آنتروپی وزن دار فیچرها به شرح زیر است:

$$AE(Domain) = 0.911$$

$$AE(Format) = 0.892$$

$$AE(Length) = 0.694$$

$$AE(Complain) = 0.788$$

در اینجا مشاهده می شود که بیشترین Information gain را فیچر طول ایمیل دارد در نتیجه گره اولیه را طول ایمیل در نظر می گیریم. برای طول بلند داریم:

$$E(Long) = 0$$

برای طول متوسط داریم:

$$E(Medium) = I(3,2)$$

$$AE(Domain) = \frac{2}{5}I(1,1) + \frac{2}{5}I(2,0) + \frac{1}{5}I(0,1) > 0$$

$$AE(Format) = \frac{3}{5}I(2,1) + \frac{2}{5}I(1,1) > 0$$

$$AE(Complain) = \frac{3}{5}I(3,0) + \frac{2}{5}I(0,2) = 0$$

در نتیجه نرخ شکایت را که دارای بیشترین Information Gain است، به عنوان گره بعدی این شاخه در نظر می گیریم.

برای نرخ شکایت بالا داریم:

$$E(High) = I(3,0) = 0$$

که آنتروپی آن صفر شده و این گره قابلیت جداسازی کامل را دارد. حال برای نرخ شکایت پایین داریم:

$$E(Low) = I(0,2) = 0$$

برای طول کوتاه نیز خواهیم داشت:

$$AE(Format) = \frac{3}{5}I(0,3) + \frac{2}{5}I(2,0) = 0$$

در نتیجه گره را فرمت در نظر می گیریم:

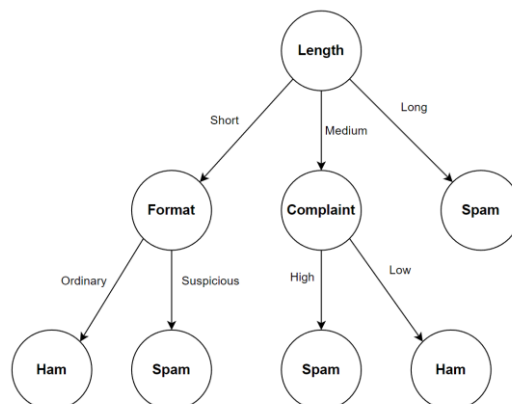
برای فرمت مشکوک داریم:

$$E(Sus) = I(2,0) = 0$$

برای فرمت نامشکوک نیز داریم:

$$E(Norm) = I(0,3) = 0$$

در نتیجه آنتروپی گره ها صفر شده و درخت تصمیم گیری با دقت ۱۰۰ درصدی بر روی دیتای آموزشی بدست آمد.



قسمت دوم) حال بر روی دیتای تست ارزیابی درخت را انجام می‌دهیم:

Number	Actual	Predicted
1	Ham	Spam
2	Spam	Ham
3	Spam	Spam
4	Spam	Spam
5	Ham	Ham
6	Spam	Spam

قسمت سوم) ماتریس Confusion را برای نتایج ارزیابی خود محاسبه و ترسیم می‌کنیم.

		Actual	
		Spam	Ham
Predicted	Spam	3	1
	Ham	1	1

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} = \frac{4}{6} = 67\%$$

$$Precision = \frac{TP}{TP + FP} = \frac{3}{3 + 1} = 75\%$$

$$Recall = \frac{TP}{TP + FN} = \frac{3}{3 + 1} = 75\%$$

قسمت چهارم)

۱. تفاوت اصلی بین روش‌های یادگیری ماشین Random Forest و درخت تصمیم در نحوه پیش‌بینی و مدیریت پیچیدگی داده‌ها نهفته است.

- درخت تصمیم: درخت تصمیم یک ساختار فلوچارت مانند است که در آن هر گره داخلی یک ویژگی، هر شاخه یک قانون تصمیم‌گیری، و هر گره برگ نشان‌دهنده یک نتیجه یا پیش‌بینی است. به صورت بازگشتی داده‌ها را بر اساس ویژگی‌های انتخاب شده برای ایجاد یک مدل درخت مانند تقسیم می‌شود. درختان تصمیم‌گیری مستعد Overfitting هستند، زیرا می‌توانند نویز و نقاط پرت را در داده‌ها ثبت کنند.
- الگوریتم Random Forest: جنگل تصادفی یک روش یادگیری گروهی است که چندین درخت تصمیم را برای پیش‌بینی ترکیب می‌کند. با انتخاب تصادفی زیرمجموعه‌هایی از داده‌ها و ویژگی‌های آموزشی، یک "جنگل" از درختان تصمیم ایجاد می‌کند. هر درخت تصمیم در جنگل به طور مستقل از یک زیرمجموعه تصادفی از داده‌ها یاد می‌گیرد و یک پیش‌بینی ارائه می‌دهد. پیش‌بینی نهایی از طریق رای‌گیری یا میانگین‌گیری پیش‌بینی تک درختان به دست می‌آید. Random Forest با میانگین‌گیری پیش‌بینی‌های چند درخت، Overfitting را کاهش می‌دهد که منجر به نتایج قوی‌تر و دقیق‌تر می‌شود.

۲. استفاده از روش Random Forest:

- Random Forest در درجه اول برای کارهای طبقه بندی و رگرسیون استفاده می شوند.
- طبقه بندی: Random Forest می تواند مشکلات طبقه بندی باینری و چند طبقه ای را مدیریت کند. آنها در مدیریت مجموعه داده های پیچیده و با ابعاد بالا موثر هستند و می توانند روابط غیرخطی بین ویژگی ها و متغیر هدف را ثبت کنند.
- رگرسیون: Random Forest همچنین می تواند برای کارهای رگرسیونی استفاده شوند، جایی که خروجی پیوسته ارائه می دهند. آنها می توانند روابط غیرخطی بین ویژگی ها و متغیر هدف را مدیریت کنند و در برابر نقاط پرت و نویز در داده ها مقاوم هستند.

مزایای Random Forest:

- جنگل های تصادفی با ترکیب چندین درخت و میانگین گیری پیش بینی های آنها، Overfitting را در مقایسه با درختان تصمیم گیری فردی کاهش می دهند.
- آنها قادر به مدیریت مجموعه داده های بزرگ با ابعاد بالا و تعامل ویژگی های پیچیده هستند.
- جنگل های تصادفی معیارهای اهمیت ویژگی را ارائه می کنند و به کاربران اجازه می دهند اهمیت و تأثیر ویژگی های مختلف بر پیش بینی را درک کنند.
- آنها از نظر محاسباتی کارآمد هستند، زیرا درختان تصمیم گیری فردی را می توان به صورت موازی آموزش داد.

۳. بایاس و واریانس دو معیاری هستند که برای ارزیابی عملکرد و تعمیم مدل های یادگیری ماشین استفاده می شوند.

- بایاس: تفاوت بین مقادیر پیش بینی شده توسط مدل و مقادیر واقعی در داده های آموزشی را اندازه گیری می کند. یک سوگیری زیاد نشان می دهد که مدل مشکل را بیش از حد ساده می کند و نمی تواند الگوهای بنیادی را به تصویر بکشد، و در نتیجه عدم تناسب دارد. درختان تصمیم گیری تمایل به تعصب بالاتری دارند، زیرا آنها فقط می توانند مرزهای تصمیم گیری نسبتاً ساده ای ایجاد کنند.
 - واریانس: واریانس تغییرپذیری یا ناپایداری پیش بینی های مدل را در مجموعه های آموزشی مختلف اندازه گیری می کند. میزان حساسیت مدل به نوسانات داده های آموزشی را کمیت می کند. واریانس بالا نشان دهنده Overfitting است، جایی که مدل بسیار پیچیده است و نویز یا نوسانات تصادفی در داده های آموزشی را ضبط می کند. جنگل های تصادفی با جمع آوری درخت های تصمیم گیری متعدد، واریانس را کاهش می دهند که منجر به پیش بینی های پایدارتر می شود.
- دلیل تفاوت در معیارهای بایاس و واریانس بین درخت های تصمیم و جنگل های تصادفی این است که درخت های تصمیم تمایل به سوگیری بالا و واریانس کم دارند، در حالی که جنگل های تصادفی هدفشان کاهش واریانس است. این Tradeoff به جنگل های تصادفی اجازه تعمیم بهتر و ارائه پیش بینی های دقیق تر در مورد داده های دیده نشده را در مقایسه با درخت های تصمیم فردی می دهد.

$$H_1 = w_1x_1 + w_2x_2 + b_1 = 0.05 \times 0.15 + 0.10 \times 0.20 + 0.35 = 0.3775$$

$$\text{Sig}(H_1) = \frac{1}{1 + e^{-H_1}} = 0.5933$$

$$H_2 = w_3x_1 + w_4x_2 + b_1 = 0.05 \times 0.25 + 0.10 \times 0.30 + 0.35 = 0.3925$$

$$\text{Sig}(H_2) = \frac{1}{1 + e^{-H_2}} = 0.5969$$

$$Y_1 = w_5H_1 + w_6H_2 + b_2 = 0.5933 \times 0.4 + 0.5969 \times 0.45 + 0.6 = 1.1059$$

$$\text{Sig}(Y_1) = \frac{1}{1 + e^{-Y_1}} = 0.7514$$

$$Y_2 = w_7H_1 + w_8H_2 + b_2 = 0.5933 \times 0.5 + 0.5969 \times 0.55 + 0.6 = 1.2249$$

$$\text{Sig}(Y_2) = \frac{1}{1 + e^{-Y_2}} = 0.7729$$

$$E_{total} = \frac{1}{2} (0.01 - 0.7514)^2 + \frac{1}{2} (0.99 - 0.7729)^2 = 0.2984$$

$$\frac{\partial E_{total}}{\partial w_5} = \frac{\partial E_{total}}{\partial \text{sig}(Y_1)} \frac{\partial \text{sig}(Y_1)}{\partial Y_1} \frac{\partial Y_1}{\partial w_5}$$

$$\frac{\partial E_{total}}{\partial \text{sig}(Y_1)} = \frac{\partial \left[\frac{1}{2} (t_1 - \text{sig}(Y_1))^2 + \frac{1}{2} (t_2 - \text{sig}(Y_2))^2 \right]}{\partial \text{sig}(Y_1)} = (-1)(t_1 - \text{sig}(Y_1)) + 0$$

$$\frac{\partial E_{total}}{\partial \text{sig}(Y_1)} = 0.7414$$

$$\begin{aligned} \frac{\partial \text{sig}(Y_1)}{\partial Y_1} &= \frac{\partial \left[\frac{1}{1 + e^{-Y_1}} \right]}{\partial Y_1} \frac{e^{-Y_1}}{(1 + e^{-Y_1})^2} = e^{-Y_1} \times [\text{sig}(Y_1)^2] = \text{sig}(Y_1) \times (1 - \text{sig}(Y_1)) \\ &= 0.1868 \end{aligned}$$

$$\frac{\partial Y_1}{\partial w_5} = \frac{\partial (w_5 H_1 + w_6 H_2 + b_2)}{\partial w_5} = H_1 = 0.5969$$

$$\rightarrow Error_{w_5} = \frac{\partial E_{total}}{\partial w_5} = 0.7414 \times 0.1868 \times 0.5969 = 0.0822$$

$$\rightarrow w_5^+ = w_5^- - \alpha \times \frac{\partial E_{total}}{\partial w_5} = 0.4 - 0.5 \times 0.0822 = 0.3589$$

قسمت دوم)

دو تابع فعال سازی محبوب مورد استفاده در شبکه های عصبی عبارتند از: واحد خطی اصلاح شده (ReLU) و تابع سیگموئید.

:(ReLU)

مزایا:

- ReLU یک تابع فعال سازی ساده است که از نظر محاسباتی کارآمد است و پیاده سازی آن آسان است.
- به دلیل توانایی آن در کاهش مشکل گرادیان ناپدید شدن، که با سایر توابع فعال سازی مانند سیگموئید یا tanh رایج است، به طور گسترده در یادگیری عمیق مورد استفاده قرار گرفته است.
- ReLU با صفر کردن مقادیر منفی، فعال سازی های پراکنده را ایجاد می کند، که می تواند با کاهش تعداد نورون های فعال، پراکندگی را افزایش داده و کارایی شبکه را افزایش دهد.
- این امکان همگرایی آموزشی سریعتر را فراهم می کند زیرا دارای یک فعال سازی خطی برای مقادیر مثبت است و از مسائل اشباع مرتبط با سایر توابع فعال سازی جلوگیری می کند.

معایب:

- ReLU می تواند از مشکل "ReLU در حال مرگ" رنج ببرد، جایی که برخی از نورون ها به طور دائم غیرفعال می شوند و دیگر هرگز شلیک نمی کنند. این زمانی اتفاق می افتد که ورودی یک نورون منفی می شود و باعث می شود که گرادیان صفر شود و نورون دیگر در طول تمرین به روزرسانی نشود.
- ReLU برای مدل هایی که نیاز به فعال سازی منفی دارند، مناسب نیست زیرا ورودی های منفی را صفر می کند و به طور موثر هر مقدار منفی را حذف می کند.

تابع سیگموئید:

مزایا:

- تابع سیگموئید دارای یک خروجی صاف و محدود بین ۰ و ۱ است که آن را برای مسائل طبقه بندی باینری که در آن خروجی احتمالات را نشان می دهد مناسب است.
- در طول تاریخ در شبکه های عصبی به عنوان یک تابع فعال سازی و به عنوان جزئی از مدل رگرسیون لجستیک استفاده شده است.

- تابع سیگموئید مشتق خوبی دارد که آن را برای الگوریتم های بهینه سازی مبتنی بر گرادیان مانند انتشار پس زمینه مفید می کند.

معایب:

- تابع سیگموئید از مشکل گرادیان ناپدید شدن رنج می برد، به ویژه برای ورودی های با بزرگی زیاد، که می تواند منجر به همگرایی کند در طول تمرین شود.
- این تابع ورودی ها را به یک محدوده محدود (۰ تا ۱) نگاشت می کند، و زمانی که ورودی دور از ۰ است، باعث "اشباع" می شود. این اشباع منجر به شیب های کوچکی می شود و توانایی مدل برای یادگیری را کاهش می دهد و روند آموزش را کند می کند.
- خروجی های تابع سیگموئید صفر محور نیستند، که می تواند یادگیری موثر لایه های زیر را چالش برانگیز کند، به خصوص در شبکه های عمیق.

شایان ذکر است که چندین activation function دیگر نیز وجود دارد که هر کدام مزایا و معایب خاص خود را دارند و انتخاب تابع فعال سازی به وظیفه خاص و معماری شبکه بستگی دارد.